# 真核生物基因组的基因分析和预测

生物信息

评分:

专业:

2015

年级:

ž	学号:	1530416014	姓名:	赵飞洋	签名:		_	
一、软硬件平台:								
1. 硬件平	≅台: (	(硬件配置)						
(1).C	PU: 2.	7 GHz Intel Co	re i7					
(2).内	存: 4 0	GB 1333 MHz [	DDR3					
(3).硬	盘:inte	el 545s 512G 臣	<b>司</b> 态					
2. 系统平	<sup>Z</sup> 台: (	(操作系统及其	[版本号)					
(1).M	ac OS	S Sierra 10.12.	.6					
3. 软件平	≅台: (	(软件系统及其	其版本号,	若是在线分	析平台,	还需要提供	URL	地
址)								
(1).R	语言:	3.3.2						

(1) pubmed: https://www.ncbi.nlm.nih.gov/pubmed/

# 二、实验方法:

- 1、基因组核酸序列的获取:
- (1)由任课教师提供【AP-genome-draft】。
- 2、创建本地 BLAST 数据库:

使用 makeblastdb 程序,对上述 FASTA 格式的基因组序列进行处理,建立本 地 BLAST 数据库。

3、己知蛋白序列的下载

根据基因组的物种来源,从 UniProt 数据库下载近缘物种已知蛋白序列, 以 FASTA 格式保存。

- 4、使用小型机上安装的 blast
- 5、同源基因搜索:
- 5.1、使用 tblastn 程序,把已知蛋白质序列和基因组草图序列建立的本地 BLAST 数据库进行比对,注意参数设置(如 e-value 设为 0.00001,建议输出格式 6 或 7。
- 5.2、编程处理 BLAST 比对结果文件,排除冗余项:
- (1)不同物种的同一种蛋白在基因组上的匹配位置存在的重叠问题;
- (2)同一物种的同一蛋白家族的不同成员白在基因组上的匹配位置存在的重叠问题;
- (3)同一个蛋白在基因组上的不同位置的高相似区域问题——是家族成员问题, 还是冗余匹配;
- 5.3、把去除冗余后的结果转成 GFF3 格式。

- 7、从头预测:
- 7.1、从网上搜索、下载并安装基因预测相关软件【至少 1 个】:
- 7.2、使用该软件对基因组序列进行基因预测分析,一方面保存预测基因编码的 多肽,另一方面将基因结构信息输出成 GFF3 格式;
- 7.3、使用 blastp 程序对该预测基因与已知蛋白序列进行比对,以此来鉴别预测的基因。

# 三、试验结果

- 1、基因组核酸序列的获取:
- (1)由任课教师提供【AP-genome-draft】。
- 2、创建本地 BLAST 数据库:

makeblastdb -in AP scaffold.fasta -dbtype nucl -parse seqids -out AP

Building a new DB, current time: 04/23/2018 14:35:42

New DB name: /home/student/s14/AP New DB title: AP\_scaffold.fasta

Sequence type: Nucleotide

Deleted existing Nucleotide BLAST database named /home/student/s14/AP


Keep Linkouts: T Keep MBits: T


Maximum file size: 1000000000B

Adding sequences from FASTA; added 36 sequences in 0.569148 seconds.

3、已知蛋白序列的下载

根据基因组的物种来源,从 UniProt 数据库下载近缘物种已知蛋白序列, 以 FASTA 格式保存。





4、使用小型机上安装的 blast



上传近缘物种序列至小型机


5、同源基因搜索:

5.1、使用 tblastn 程序,把已知蛋白质序列和基因组草图序列建立的本地 BLAST 数据库进行比对,注意参数设置(如 e-value 设为 0.00001,建议输出格式 6 或 7。

nohup tblastn -query uniprot.fasta -out res -db AP -outfmt 6 -evalue 1e-5 -num threads 8 > out &

nohup tblastn -query uniprot.fasta -out res1 -db AP -outfmt 7 -evalue 1e-5 -num\_threads 8 > out1 &

5.2、编程处理 BLAST 比对结果文件,排除冗余项:



```
sp|Q9C102|GLT1_SCHP0
                             scaffold_3
                                                     2129
                                                                                        1470261 1476635 0.0 2965.0
                                           67.54
sp | A2QLK4 | FKS1_ASPNC
                             scaffold_1
                                                                         13
                                           76.84
                                                     1831
                                                                              1832
                                                                                        4053828 4059203 0.0 2736.0
sp|P34229|FAS1_YARLI
                             scaffold_1
                                                               809 19
                                                                                       3137887 3131690 0.0 2533.0
                                           59.88
                                                     2086
                                                                              2082
sp | Q4WF53 | NRPS4_ASPFU
                             scaffold_7
                                           62.75
                                                     1917
                                                               695 12
                                                                         145
                                                                             2053
                                                                                       1600975 1595258 0.0 2448.0
sp | 014187 | SPP42_SCHP0
                            scaffold_13 73.53
                                                     1526
                                                                         50 1567
                                                                                       999505 1004076 0.0 2331.0
sp|Q12553|XDH_EMENI scaffold_4 72.74
                                               1372
                                                                   29
                                                                         1363
                                                                                 1568039 1563924 0.0 2044.0
                            scaffold_5 46.39
                                                                         34 84 2282
sp | Q12019 | MDN1_YEAST
                                                     2272
                                                               1102
                                                                                            855494 848808 0.0 1922.0
sp|Q9Y719|M0K13_SCHP0
                                                                         39 1 2358
59 1 3137
                             scaffold_1 42.19
                                                     2318
                                                               1189
                                                                                            2621619 2614293 0.0 1921.0
sp | Q07878 | VPS13_YEAST
                            scaffold_6 35.2
                                                                                            1447995 1457600 0.0 1894.0
                                                     3273
                                                               1914
                                                        1115 28 7 2151 2961180 2954701 0.0 1862.0
54 409 23 37 1512 859086 854536 0.0 1817.0
32 1339 44 6 2358 1648137 1655654 0.0 170
10 353 8 18 1193 2428679 2425071 0.0 1690.0
sp|Q03149|WA_EMENI scaffold_1 45.2 2197
sp|Q0UJ42|NTE1_PHAN0 scaffold_13 66.28
                                                     1554
sp|Q9Y719|M0K13_SCHP0
                            scaffold_7 39.02
                                                     2532
                                                                                           1648137 1655654 0.0 1702.0
sp|A5DHT2|RPB2_PICGU
                             scaffold 1 67.44
                                                     1210
sp|P32639|BRR2_YEAST
sp|043065|MOT1_SCHP0
                            scaffold_3 41.48
scaffold_6 46.67
                                                                         38 1 2160
                                                                                          1828828 1835361 0.0 1611.0
                                                     2225
                                                               1190
sp|043065|MOT1_SCHPO scaffold_6 46.67 1864 881 27 153 1948 1193653 1199109 0.0 1543.0
sp|Q9HEH1|RENT1_NEUCR scaffold_2 69.93 1124 296 11 4 1091 904443 901090 0.0 1540.0
sp|P22944|NIR_EMENI scaffold_4 70.33 1055 297 8 60 1102 1844667 1847819 0.0 1508.0
                                                               35 6 1 1239
384 9 22 1147
859 23 1 1684
565 5 135 1481
880 29 462 2223
sp|P38095|LAMA_EMENI
                            scaffold_3 59.88
                                                     1194
                                                                                       1554508 1558336 0.0 1469.7
sp|P22276|RPC2_YEAST
sp|P15398|RPA1_SCHP0
sp|Q10250|YD22_SCHP0
                             scaffold_3 62.7
                                                                                       181497 178057 0.0 1462.0
                                                     1161
                            scaffold_1 45.41 scaffold_1 52.33
                                                                                       1327838 1322667 0.0 1458.0
                                                     1753
                                                     1307
                                                                                       2350824 2346650 0.0 1455.0
sp|Q01631|CYAA_NEUCR
                            scaffold_10 45.94
                                                     1800
                                                                                       1267599 1272833 0.0 1454.0
                                                     1328 545 13 1 1317 432282 428359 0.0 14
988 227 5 48 1005 800312 803272 0.0 1444.0
sp|Q10094|YA0F_SCHP0
                             scaffold_6 56.63
                                                                                       432282 428359 0.0 1452.0
sp|093937|PYR1_EMENI
                             scaffold_12 73.89
                                                               421 6 7 1215 7
1477 46 163 2661
sp|Q00737|SUDA_EMENI
                             scaffold_13 59.74
                                                     1145
                                                                                       798872 802575 0.0 1435.0
sp|Q10105|GCN1_SCHP0
                            scaffold_9 38.49
                                                     2549
                                                                                          433308 440831 0.0 1427.0
                                                     967 253 6 113 1057 2240403 2243294 0.0 1375.0 912 252 7 107 1038 587052 584195 0.0 1363.5
sp|Q4X0Z7|L0NM_ASPFU
                            scaffold_2
                                           71.25
                            scaffold_1 70.07
scaffold_9 62.49
sp|P00365|DHE2_NEUCR
sp | Q9Y767 | DPOG_NEUCR
                                                               344 9
                                                                                       1170224 1167246 0.0 1362.0
                                                     1037
                                                                         62 1097
sp | Q4P9K9 | CHS8_USTMA
                            scaffold_10 42.75
                                                               826 29 107 1757
                                                                                       209215 214092 0.0 1351.0
                                                     1717
sp | 013396 | MSH2_NEUCR
                            scaffold_10 70.54
                                                     937 257 7
                                                                         937 1023034 1025787 0.0 1328.0
                            scaffold_11 58.18
                                                     1162
                                                               455 11
                                                                                       257081 253659 0.0 1328.0
sp|074298|LYS2_PENCH
                                                                         258 1409
sp|Q1K9C2|MET5_SCHP0 scaffold_2 53.88 1236 532 15
sp|Q06625|GDE_YEAST scaffold_7 47.25 1471 693 24 88
                                                                        245 1458
                                                                                       1675465 1679124 0.0 1318.0
                                                                        1510 977509 973202 0.0 1316.0
sp|Q10178|SF3B1_SCHP0
sp|A2R1F6|MSH3_ASPNC
                          scaffold_13 60.53
                                                     1140
                                                               381 8
                                                                         105 1201
                                                                                       939739 936398 0.0 1303.0
                                                                                       1281480 1278148 0.0 1293.0
                             scaffold_7 61.85
                                                     1135
                                                               390 18
                                                                         4 1119
```

去除冗余后的结果,保留了4268条记录,处理脚本名为operate.py

## 7、从头预测:

- 7.1、从网上搜索、下载并安装基因预测相关软件【至少 1 个】:
- a. 下载 GeneMark



b. 移动 key 至工作目录下

c. 安装 perl 依赖

sudo cpan YAML

sudo cpan Hash::Merge

sudo cpan Logger::Simple

sudo cpan Parallel::ForkManager

sudo cpan Getopt::Long

sudo cpan File::Spec

sudo cpan File::Path

sudo cpan Data::Dumper

JKEENAN/File-Path-2.15.tar.gz /usr/bin/make install -- OK

XSAWYERX/PathTools-3.74.tar.gz /usr/bin/make install -- OK

JV/Getopt-Long-2.50.tar.gz /usr/bin/make install -- OK

YANICK/Parallel-ForkManager-1.19.tar.gz /usr/bin/make install -- OK

TSTANLEY/Logger-Simple-2.0.tar.gz /usr/bin/make install -- OK REHSACK/Hash-Merge-0.300.tar.gz /usr/bin/make install -- OK

TINITA/YAML-1.24.tar.gz /usr/bin/make install -- OK

SMUELLER/Data-Dumper-2.161.tar.gz /usr/bin/make install -- OK

d. 测试是否成功

# ./gmes\_petap.pl

e.发现 mac 版缺少—predict\_with 参数,由于此工具为 perl 脚本工具,故在 mac 上试用 Linux 版本脚本,但执行命令依然有问题,为无法运行二进制文件

cannot execute binary file

f.故将原来下载的 mac 版文件夹中的 Gibbs3、gmhmme3、probuild 三个二进制文件替换至 linux 版本文件夹下,运行成功

7.2、使用该软件对基因组序列进行基因预测分析

```
./gmes_petap.pl --prediction --fungus
--predict_with ./heu_dir/heu_05_gcode_1_gc_38.mod
--sequence ./AP_scaffold.fasta
```

```
./AP_scaffold.fasta
here: ./heu_dir/heu_05_gcode_1_gc_38.mod
```

./get\_sequence\_from\_GTF.pl genemark.gtf AP\_scaffold.fasta

\$./get\_sequence\_from\_GTF.pl genemark.gtf AP\_scaffold.fasta
\$

#### >1\_(

LHNELLELGWTGAGKSLDDLETSTWFDIWGQEADNCRDNLSDDLIAFLERAQMPRAGEEHSLFFYVYGLAHPKRLWDTFEWRFEEPDKHRYVTLFLANLGPSHPDGL
AFDQKTNKAIMQMSIHDASITLNGRTPWLPLEVILSAWLDMVDVGKVRAVDDSVEANEKFDPWICCHWNQGMVQETVKAFNALLDSIESRMEDQGFVVTDSKPPLLP
DATLEAAGIPNGFARSFFTQPRRPGFRYIAPDISIPSPGSFLQQPFSSIMHDEQDEDPDEDELIIEPILLFASSSHVSLANEEDKYHPFPWPYNQLLSFPAGLYLTD
SERSAGHEFEDGVKFVLPYGVGGKGFARTSDGLHIGDPRDEQDARCEDRLADLYQQGWNPFIEMHEVRLVKVLESWIEMVERGDWKVGPEGVEGSIDAFKEAETPEG
WERFVVPMGW

#### >2\_g

MAHLLHRSVDSETAALILQLQRDDIEAALCQGDAHENVALQLQMQQLNLVETAHNDYTIAQSISRAVFDDRDLLTEELSAEQQAMRDRQLAQRLPQGADIPLDDSTL
TDNSEDDVNDRELSITCVACTNTFPWFDILETPCSHHYCVECLSELFDLSMKDETLYPPRCCRQTIPLDDAKLVLHPKLVRDFQQKSIELDAKDRTYCYDPRCSTFI
PAEHITEDVADCPDCGKRTCVICKAAAHRGDCPRDEDLQQLLQAAEHAVFVGPAQIIPAPFARPINSFLIQNAPVPRPAARPAAQAAPDLPAPAVRAVPAPAVRAVP
VPAAPVARPAAPAAPVPVPPARPAHAQAVGVVPVPAARPPTPAVRAVPPAPAALATRPAVPTARAVSVPAVRPIAQDIVTNRQQRVVAQIRADLQRNHECDHERWTLE
NTLSGTIMPLDEIHNISTWAHAQDTPLHMHLDGAQLWETVVAGAGSLQEFTSCFDSVSLWFTKGLGAPIGSIIVGNAKFIQRARMIRKLLGGGLRQLGVIAGPAEVA
IEQVFLGGGLATAHRYARRLAKSWEDFGGKLONPTETHMVWLDLEPAGVAGDTFADLAKCHGVLTMRRRLQRRLVLHYQICQDALQSIERLFYFVLNGRKCSTSVSS

#### >3\_g

MQAILPGRPQAQLQAVSTGAFEGQTVICYISGNALIICNGPDSLLQTIYHDDLLPPSALVAVSYDHRTAKIATASSDNVYIVVLREEIKGQLRWFLDMTFALASGSI
RTLSWGTDDELLVASDKLLLLSTQDNSIRWTRSLPSPVSHATFSPSAALLATTSQYDRLVKVWRRLSFESAIFDYAYLTHPDIVTHLEWRKDSADQDVLYTICLDGR
LRVWKTALPHQIDVLGLYADLDLTKAVRPLVPSNRRYASLVPSSVFSDAVEHAVNTPTLPAERHAIEYMKELAKRNPDIVVVTDDQGHMSAWGLENVGCKTRTSNTE
HAEFFHATHVENLFFDFSKHAQIDEDNARIINFALPGQPGDIALLVHHFDGRLQWYGRVHHVFDPSPRKHRMRNLASWTGHSSSIKKLIRTANGSAVISRTDTDEG
VVWKHRAKFLARKSKVKLQEHIHRTVLLQDGDFVVLLHHQSISLWDARLPNAKEIGRCPYSVSGKPLCLVLLPAPEDAGHLSYLATVTADMHGVVWELDLASPSPTI
TEFCAFQLDRIENMSYFLPVDPAGSSPVVSGLFDTFAQDVAVSWTTTGILQTWTAKVDRLNKSVTWLNISTTDTTIQDPSLGSGTSIRKAALVDKSRSTLTIWDTKS
GRLDYETFENQTIQDLDWASTPDNQSILAVGFPHAVFVYTQLRYDYVTERPSWGRIKQINVRNLSPHPIGDSVWLGSGNLIIGAGNQLYLAGNEVDPQKDLSPDLQ
GSTPHKSSTRIQDVVRRLNGPLPVFHPQFISQCILAGKMDIVHRILLNLQKTLKFYTEGDDLDSFQGLDIEDFITLDMQEESTAVTEEVAQSLVSULLSEKSVPQLSS
TEQLSLADTIECVGMAEKHRRSIDENAARYLLFWRETVMRSRQSSSSAAVTWREMLWAYHSTSQDILVDLVTRQNKGQMTWSHARDTGVFVWLTDREALLQQFEAVA
RSAYTSTELRDPVNCSLHYLALRKKNVLTGLWRMATWSREQAATMRLLKNDFTDPRWRTAANKNAVALMGKRRFEYAAAFFLLADNLDSAVSVLSNQLGDVQLAIAV
ARVYGGDDSPSLKKFLTERVLPNAALDGNRCQATWTYWMLGERSSAVRALVSPLHSLLDPPGSPPDSLQAKSFRNDDPALVVLYQQLREKSLQTLRGALMISGNEW
EFITKTATLLLRMGCDILALDLVRHWEFLHPPPVAKQEEQEEEVEESVAELPRRLSRTTTDDFPRKLTRRSSLVVADLPEGRPVVHETGAPSMLDGWSAPSSQG
QQPSSLLDQWTVPASSAAKPAPSMLEQWSNPERPKQQANPAPLMLDNWATPJAKKPSIESTKAAPLSLLDQWTVPPVSSKPVPTMPDQLKEPIVTSSESAVEGSQFL
ANPTMPTSMPNSANDDAKLGETMVIIQDHGASKSEPNGNESQNEEDPKAETQKSSKTGKMGDEKAEEYKLPKGLKQPPPEAFKEPDPNSLLDAFGF

#### >1 q

#### >2<u>g</u>

AAATGTCGCTCTCCAACTGCAAATGCAACAGCTCAACCTTGTCGAAACTGCGCACAACGATTACACCATCGCTCAGAGCATTTCGCGCGCAGTTTTCGACGACCGTG ACTTGCTGACAGAGGAACTGTCTGCCGAGCAGCAGCGAGGAGAGACCGCCAGCTAGCACAACGACTCCCTCAGGGCGCTGACATCCCGCTTGACGACCCTC ACCGACAACAGCGAAGACGACGTTAACGATCGCGAGTTGTCCATCACTTGTGTGGCCTGTACCAATACCTTTCCTTGGTTCGACATTCTCGAAACTCCCTGCAGTCAAGCTCGTGCTTCATCCCAAACTTGTCAGAGATTTCCAGCAGAAGTCCATTGAGCTTGATGCTAAGGACAGAACCTACTGCTATGATCCTCGTTGTTCGACATTCATC AGATCTTCAGCAGCTTCTCCAGGCCGCCCGAGCATGCCGTCTTTGTCGGACCTGCTCAGATTATTCCTGCTCCTTTTTGCTCGCCCCTATTAACAGCTTTCTCATCCAGA ACGCCCCAGTCCCTCGCCCTGCCGCTCGTCCCGCCCCCTCAGGCTGCCCCCGACCTCCCAGCCCCAGCTGTTCGTGCTGTACCCGCTCCAGCTGTCCGCGCTGTGCCC GTCCCAGCGGCCCCAGTCGCTCGTCCCGCCCGCCGCCGCTGCTCCTGTCCCAGTTCCACCTGCTCGCCCTGCTCAAGCTGTCGGTGTTGTGCCCGTGCCAGC TGCTCGCCCTCCCACCCCAGCCGTTCGCGCCGTACCTGCTCCAGCTGCACTTGCCACTCGTCCTGCAGTCCCGACTGCTCGTGCGGTGTCTCTCCCGGCCGTGCGTC AACACATTGTCTGGGACGATCATGCCACTGGACGAGATTCATAACATCTCAACTTGGGCCCATGCCCAAGATACCCCACTCCATATGCACTTAGACGGCGCTCAATT GACCCACATGGTTTGGCTTGATCTGGAGCCTGCAGGCGTCGCCGGTGATACTTTTGCAGACCTGGCCAAGTGTCATGGTGTGCTGACAATGAGGAGAAGGCTTCAGC 

- 7.3、使用 blastp 程序对该预测基因与已知蛋白序列进行比对,以此来鉴别预测的基因。
- a. 建立己知蛋白数据库

```
(/opt/BioBuilds)-bash-4.2$ makeblastdb -in uniprot.fasta -dbtype prot -parse_seqids -out PRO

Building a new DB, current time: 04/29/2018 00:37:09

New DB name: /home/student/s14/PRO

New DB title: uniprot.fasta

Sequence type: Protein

Keep Linkouts: T

Keep MBits: T

Maximum file size: 1000000000B

Adding sequences from FASTA; added 33161 sequences in 2.494 seconds.
```

# b. 使用 blastp 进行比对

nohup blastp -query prot\_seq.faa -out prores -db PRO -outfmt 6 -evalue 1e-5 -max\_target\_seqs 1 -num\_threads 8 > out &

```
50.73
2_g sp|D7PHZ0|VRTJ_PENAE
                                     205 95
                                                  427 631 179 377 1e-49
                                              840 35 4
3_g sp|P47104|RAV1_YEAST
                             27.85
                                      1397
                                                           1326
                                                                   5 1307
                                                                                4e-155 512
9_g sp|D4B3C8|A2965_ARTBC
                            29.08 306 168 7 623 895 65 354 7e-23 105
                                         354 205 8 32 361 84 415 4e-29
487 292 15 34 496 29 499 2e-53
10_g
        sp|014031|PGT1_SCHP0
                                 29.10
                                                                                120
        sp | D4B1P2 | A2372_ARTBC
11_g
                                 31.83
                                                                                190
        sp | A2QHE5 | FDC1_ASPNC
                                          502 146 2 299 799 7
                                                                  498 0.0 727
                                 68.73
                                         502 146
222 83 1 1
26 2 1
        sp|P36619|PMD1_SCHP0
sp|P36619|PMD1_SCHP0
13_g
                                 42.34
                                                           222 1153
                                                                       1329
                                                                                9e-48
                                                                                        171
                                          230 86 2
                                                           222 454 638 1e-39
                                 39.57
                                                                                148
        sp|P25386|US01_YEAST
sp|Q8TFZ1|XRN2_ASPFU
14_g
                                 26.51
                                         1260 726 39 1 1141
                                                                      7 1185
                                                                                    1e-89
                                                                                            320
                                         910 301 11 1
131 69 2 68
                                                           889 1 904 0.0 1153
197 21 148 3e-26
                                 63.96
16_g
        sp|Q09776|SNU23_SCHP0
                                 44.27
                                                                                102
                                          265 155 11 1
        sp|C1GQH3|P20D1_PARBA
                                                           262 124 354 3e-10
18_g
                                 27.55
                                                                                62.4
        sp N4WE43 RED2_COCH4
                                          197 117 1
                                 39.09
                                                      69
                                                           265 67 260 3e-43
                                                                                153
        sp|P38860|MTG2_YEAST
                                 37.85
                                         391 190 9
                                                      85
                                                          448 91 455 3e-50
                                                                                186
                                         82 51 1
91 52 4
22_g
        sp|014064|BIR1_SCHP0
                                 36.59
                                                      5
                                                           85 116 197 3e-14
                                                                                76.6
22_g
        sp|014064|BIR1_SCHP0
                                                          104 31 120 2e-06
                                                     22
                                 32.97
                                                                                51.6
        sp|074339|TAM41_SCHP0
                                         413 196 8 28 440 48 390 5e-63
23_g
                                 35.59
                                                                                219
26_g
        sp|Q6CE48|IND1_YARLI
                                 66.67
                                          60 20 0
                                                           60 142 201 6e-20
                                                                                91.3
        sp | Q0UPL5 | PAN2_PHAN0
                                         189 89 0
                                                           189 153 341 3e-67
27_g
                                 52.91
                                                                                224
28_g
        sp | Q0UPL5 | PAN2_PHAN0
                                          132 61 0
                                                           132 349 480 4e-43
                                                                                154
                                 53.79
29_g
        sp | Q0UPL5 | PAN2_PHAN0
                                          558 203 7
                                                           555 535 1084
                                 61.65
                                                      1
                                                                           0.0 685
        sp|Q9Y7B6|PANB_EMENI
                                 69.83
                                          295 71 1
                                                      2
                                                           296 72 348 7e-153 436
35_g
        sp|Q7SIC2|QD0I_ASPJA
                                 52.23
                                          337 153 6
                                                      670 1002
                                                                   15 347 7e-101 324
36_g
        sp|P13586|ATC1_YEAST
                                          918 335 15
                                                           905 111 938 0.0 874
                                 52.29
                                         372 229 13 86 416 5 372 3e-20 92.
286 60 1 38 322 32 317 6e-150 446
        sp|A0A024SMV2|XDH_HYPJR 26.34
                                                                               92.4
        sp | P0C582 | M20M_NEUCR
                                         286 60 1 38 322 32 33
1283 802 33 78 1298
42_g
                                  78.67
        sp|059810|VGL1_SCHP0
                                                                                   2e-126
                                 26.11
                                                                       87 1285
46_g
        sp | 094387 | YGSA_SCHP0
                                 25.00
                                          296 168 13 735 999 1287
                                                                       1559
                                                                                2e-06
                                                                                        52.4
                                          80 50 1
        sp|P17442|PH081_YEAST
                                                      1049
                                                                       571 650 9e-06
                                                                                        50.4
                                 36.25
                                                               1127
48_g
        sp|Q4WHU1|HPPD1_ASPFU
                                 69.11 246 75 1
                                                      236 481 115 359 3e-122 367
49_g
        sp|D2YW48|GST_COCIM 44.97 149 79 2
                                                      146 82 230 1e-37 131
                                         171 75 2
                                 48.54
                                                      50 210 100 267 2e-43
        sp | P34909 | N0T4_YEAST
        sp|S0ARX1|FSDH_FUSHE
                                          378 234 6
                                                      13 373 18 388 1e-48
                                 31.75
                                                                                182
        sp|P86029|HQD2_CANAL
                                 36.39
                                          305 182 6
                                                      6
                                                           302 2
                                                                   302 3e-59
                                                                                195
        sp|Q9C0V4|Y0M2_SCHP0
                                 34.21
                                          228 103 4
                                                      471 690 558 746 7e-31
                                                                                130
        sp | Q8NK50 | MTDH_HYPJE
                                 35.53
                                          273 162 8
                                                      29 297 2
                                                                   264 6e-43
                                                                                150
        sp|Q4INZ9|FKBP4_GIBZE
                                 50.22
                                          458 179 12
                                                           433 62 495 7e-97
                                                                                303
                                                      1
                                                      319 447 211 333 1e-31
        sp10946231REV1_SCHP0
                                 50.38
                                          131 55 3
```

c. 编程在 gtf 中加入比对的 query 名,代码为 genemark.py

```
. "gene_id ""1_g""; transcript_id ""1_t"";"
"gene_id ""1_g""; transcript_id ""1_t"";"
. + 0 "gene_id ""1_g""; transcript_id ""1_t"";"
scaffold_1
            GeneMark.hmm
                            CDS 721 2039
scaffold 1 GeneMark.hmm
scaffold 1 GeneMark.hmm
                            stop codon 2037
                                                 2039
                                                         - . "gene_id ""2_g""; transcript_id ""2_t"";"
scaffold_1 GeneMark.hmm
sp|D7PHZ0|VRTJ_PENAE
                                                         . - 0 "gene_id ""2_g""; transcript_id ""2_t"";"
scaffold_1 GeneMark.hmm
                            stop_codon 3579
                                                 3581
  sp|D7PHZ0|VRTJ_PENAE
scaffold_1 GeneMark.hmm
                             CDS 3579
                                         4230
                                                         1 "gene_id ""2_g""; transcript_id ""2_t"";"
sp|D7PHZ0|VRTJ_PENAE
scaffold_1 GeneMark.hmm
                             exon
                                  8096
                                             8585
                                                         - . "gene_id ""2_g""; transcript_id ""2_t"";"
sp|D7PHZ0|VRTJ PENAE
scaffold 1 GeneMark.hmm
                                                         2 "gene_id ""2_g""; transcript_id ""2_t"";"
                            CDS 8096
                                         8585
sp|D7PHZ0|VRTJ_PENAE
scaffold_1 GeneMark.hmm
                                                                  "gene_id ""2_g""; transcript_id ""2_t"";"
                             exon 8984
sp|D7PHZ0|VRTJ_PENAE
                                                             "gene_id ""2_g""; transcript_id ""2_t"";"
scaffold 1 GeneMark.hmm
                            CDS 8984
                                         9770
sp|D7PHZ0|VRTJ_PENAE
scaffold_1 GeneMark.hmm
                                                             - 0 "gene_id ""2_g""; transcript_id ""2_t"";"
                             start_codon 9768
                                                 9770
   sp|D7PHZ0|VRTJ_PENAE
scaffold_1 GeneMark.hmm
                                                                  "gene_id ""3_g""; transcript_id ""3_t"";"
                            exon
                                     10775
                                           13242
SD|P47104|RAV1 YEAST
scaffold_1 GeneMark.hmm
                                                        . + 0 "gene_id ""3_g""; transcript_id ""3_t"";"
                            start codon 10775
                                                 10777
   sp|P47104|RAV1_YEAST
scaffold_1 GeneMark.hmm
                                                    + 0 "gene_id ""3_g""; transcript_id ""3_t"";"
sp|P47104|RAV1_YEAST
                                                    0 + . "gene_id ""3_g""; transcript_id ""3_t"";"
scaffold 1 GeneMark.hmm
                            exon
                                   13347 15663
sp|P47104|RAV1_YEAST
scaffold_1 GeneMark.hmm
                                                . + 1 "gene_id ""3_g""; transcript_id ""3_t"";"
                            CDS 13347 15663
sp|P47104|RAV1_YEAST
scaffold_1 GeneMark.hmm
sp|P47104|RAV1_YEAST
scaffold_1 GeneMark.hmm
scaffold_1 GeneMark.hmm
                            stop_codon 15661 15663 . + 0 "gene_id ""3_g""; transcript_id ""3_t"";"
                                                                  "gene_id ""4_g""; transcript_id ""4_t"";"
0  "gene_id ""4_g""; transcript_id ""4_t"";"
                            exon 16523 17596
                                                             + 0
                            start_codon 16523
                                                 16525
                                                    CDS 16523 17596
stop_codon 17594
scaffold_1 GeneMark.hmm
scaffold_1 GeneMark.hmm
                                                 17596 . + 0
```

# 三、实验讨论:

1.对 blast 比对结果文件进行去除冗余处理时,我分了三步,首先区分正、负链,之后将正、负链结果进行合并多外显子、去除冗余,这里出现了一个问题。如果 先进行多外显子的合并,由于原数据中有大量冗余结果,一旦合并,会产生非常 长的链,之后进行去冗余操作,这些长链会将本不该被去除的区域消除。如下图 所示

## 合并后

由图中可知,原本下面的两段序列不会被消除,但是如果先进行合并处理,下面 两条序列就会被当作冗余处理。所以先进行去冗余操作,再合并多外显子。 2.不同物种的同一蛋白在核酸序列相同位置匹配,说明此蛋白保守性较好;而不 同蛋白在核算序列同一位置匹配上,则可能是此区域保守性较差,或者只是这些 蛋白重复性较高。理论上讲,核算序列的某一位置应该只有一个蛋白与之匹配。

# 3.结果文件:

## a. 同源基因搜索

res: blast 结果 format-6

res1:blast 结果 format-7

result: 去冗余并合并多外显子结果

## b. 从头预测

genemark.gtf、prot\_seq.faa、nuc\_seq.fna: 从头预测原始结果

prores: blastp 结果

proteinblast:添加 query 名的结果

# c. 脚本

operate.py: 去冗余、合并多外显子

genemark.py:添加 query 名至 blastp 结果